

# Методы зеркальных отображений в задачах выпуклой ОПТИМИЗАЦИИ

Ефремов С.В., Якушев А.Ю.

8 июня 2019 г.

## 1 Введение

Метод зеркального спуска является естественным обобщением метода проекции субградиента в случае обобщения  $l_2$  нормы на более общий случай какой-то функции расстояния. В этой работе мы представляем новый подход к построению субградиентной схемы для различных негладких задач выпуклой структуры. Так мы не ограничиваемся построением стандартного метода зеркального спуска, но рассматриваем его вариацию — метод двойственных усреднений, ускоряем алгоритмы методом подобных треугольников, попутно изучая вопрос выбора констант для его оптимальной работы.

## 2 Постановка задачи

Рассмотрим следующую задачу выпуклой оптимизации — задана функция  $f(x)$  и оракул также выдает ее градиент  $\nabla f(x)$ . Задача найти  $\min_{x \in \mathbb{R}} f(x)$ .

### 2.1 Сопряженная норма:

*Определение:* Сопряженной нормой  $\|\cdot\|_*$  к данной  $\|\cdot\|$  называется:

$$\|y\|_* = \max\{\langle y, x \rangle : \|x\| = 1\}$$

Пример:  $(\|\cdot\|_p)_* = \|\cdot\|_q$ ,  $\frac{1}{p} + \frac{1}{q} = 1$

Неравенство Гельдера:

$$\sum_{k=1}^n |x_k y_k| \leq \left( \sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \left( \sum_{k=1}^n |y_k|^q \right)^{\frac{1}{q}} \text{ for all } x, y \in \mathbb{C}^n$$

Свойства:

- Двойственная норма  $\|\cdot\|_*$  является нормой
- $l_2$  норма сопряжена сама себе
- Двойственная норма к двойственной норме - исходная норма
- $(\|\cdot\|_1)_* = \|\cdot\|_\infty$ ,  $(\|\cdot\|_\infty)_* = \|\cdot\|_1$
- Обобщенное неравенство Коши Шварца:  $\langle y, x \rangle \leq \|y\|_* \|x\|$ , следствие:  $\|x\|^2 \pm 2\langle y, x \rangle + \|y\|_*^2 \geq 0$

## 2.2 Дивергенция (расстояние) Брэгмана

Попробуем интуитивно ввести понятие обобщенного расстояния, именуемого расстоянием Брэгмана. Для каждой точки  $y$  она возвращает расстояние этой точки до  $x$  -  $V_x(y)$ . В самом простом случае можно взять  $V_x(y) = \frac{1}{2}\|x - y\|^2$ ,  $\nabla V_x(y) = y - x$ . Рассмотрим уже классическую запись:

$$\begin{aligned} \|x_{k+1} - y\|^2 &= \|x_{k+1} - x_k\|^2 + \|x_k - y\|^2 - 2\langle x_k - x_{k+1}, x_k - y \rangle \\ V_{x_{k+1}}(y) &= V_{x_{k+1}}(x_k) + V_{x_k}(y) - \langle \nabla V_{x_{k+1}}(x_k), x_k - y \rangle \end{aligned}$$

Для вводимого обобщенного расстояния будем требовать выполнения, кроме того (как будет видно при получении оценок), приятным свойством было бы еще следующее требование:

$$V_x(y) \geq \frac{1}{2}\|x - y\|^2$$

*Определение:* Дивергенцией (расстоянием) Брэгмана называется функция следующая  $V_x(y)$ . Пусть  $S \subseteq \mathbb{R}^n$  - замкнутое выпуклое множество, тогда функция  $\phi : S \rightarrow \mathbb{R}$  называется прокс-функцией (distance generating function), если  $\phi$  является 1 - сильно выпуклой, т.е.:

$$\phi(y) \geq \phi(x) + \langle \nabla \phi(x), y - x \rangle + \frac{1}{2}\|y - x\|^2, \quad \forall x, y \in S$$

Тогда прокс-функцией индуцируется **расстояние Брэгмана**:

$$V_x(y) = \phi(y) - \phi(x) - \langle \nabla \phi(x), y - x \rangle$$

Заметим, что определение сильной выпуклости зависит от выбора прямой нормы  $\|\cdot\|$ . Это важное замечание, поскольку именно это свойство позволит в будущем подстраивать расстояние под геометрию пространства.

Свойства:

- Аксиома тождества  $V_x(x) = 0$
- Совместимость с Евклидовой нормой:  $V_x(y) \geq \frac{1}{2}\|x - y\|^2 \geq 0$
- (Не)равенство треугольника:  $\langle -\nabla V_x(y), y - z \rangle = V_x(z) - V_y(z) - V_x(y)$

## 2.3 Вернемся к задаче

Пусть задано выпуклое замкнутое множество  $S \in \mathbb{R}^n$ , кроме того, есть алгоритм оптимизации, возвращающий последовательность точек  $x_1, \dots, x_k, \dots$ . Тогда запишем (не)равенство треугольника для расстояния Брэгмана, полагая  $y = x_{k+1}$ ,  $x = x_k$  и произвольный  $z \in S$  (который мы в дальнейшем для целостности изложения будем обозначать  $y$ )

$$\begin{aligned} \langle -\nabla V_{x_k}(x_{k+1}), x_{k+1} - z \rangle &= V_{x_k}(z) - V_{x_{k+1}}(z) - V_{x_k}(x_{k+1}) \\ \langle -\nabla V_{x_k}(x_{k+1}), x_{k+1} - y \rangle &= V_{x_k}(y) - V_{x_{k+1}}(y) - V_{x_k}(x_{k+1}) \end{aligned} \quad (\text{baseMD})$$

Просуммируем полученные равенства:

$$\sum_{k=0}^{T-1} \langle -\nabla V_{x_k}(x_{k+1}), x_{k+1} - y \rangle = V_{x_0}(y) - V_{x_T}(y) - \sum_{k=0}^{T-1} V_{x_k}(x_{k+1})$$

Имея ввиду полученное уравнение, давайте, наконец, попробуем сформулировать метод **зеркального спуска**:

$$x_{k+1} = \arg \min_{x \in S} (\langle \alpha_k g_k, x \rangle + V_{x_k}(x))$$

Посмотрим внимательнее на условие проекции для точки  $x_{k+1}$ :

$$\langle \alpha_k g_k, x_{k+1} - y \rangle + \langle \nabla V_{x_k}(x_{k+1}), x_{k+1} - y \rangle \leq 0$$

$$\langle \alpha_k g_k, x_{k+1} - y \rangle \leq -\langle \nabla V_{x_k}(x_{k+1}), x_{k+1} - y \rangle$$

Попробуем теперь получить наше базовое неравенство, используя (baseMD):

$$\begin{aligned} \langle \alpha_k g_k, x_k - y \rangle &\leq -\langle \nabla V_{x_k}(x_{k+1}), x_{k+1} - y \rangle - \langle \alpha_k g_k, x_{k+1} - x_k \rangle = \\ &= V_{x_k}(y) - V_{x_{k+1}}(y) - V_{x_k}(x_{k+1}) - \langle \alpha_k g_k, x_{k+1} - x_k \rangle \leq \\ &\leq V_{x_k}(y) - V_{x_{k+1}}(y) - \frac{1}{2} \|x_k - x_{k+1}\|^2 - \langle \alpha_k g_k, x_{k+1} - x_k \rangle \leq \\ &\leq V_{x_k}(y) - V_{x_{k+1}}(y) + \left( \langle \alpha_k g_k, x_k - x_{k+1} \rangle - \frac{1}{2} \|x_k - x_{k+1}\|^2 \right) \leq \\ &\leq V_{x_k}(y) - V_{x_{k+1}}(y) + \frac{\alpha_k^2}{2} \|g_k\|_*^2 \end{aligned}$$

ТЕЛЕСКОПИРУЕМ

$$\begin{aligned} \sum_{k=0}^{T-1} \langle \alpha_k g_k, x_k - y \rangle &\leq V_{x_0}(y) - V_{x_T}(y) + \sum_{k=0}^{T-1} \frac{\alpha_k^2}{2} \|g_k\|_*^2 \\ &\leq V_{x_0}(y) + \sum_{k=0}^{T-1} \frac{\alpha_k^2}{2} \|g_k\|_*^2 \\ &\leq M + \frac{\alpha^2 G^2 T}{2} \end{aligned}$$

Здесь мы подразумеваем  $\|g_k\|_* \leq G$  равномерно по  $k$ , а  $V_{x_0}(y) \leq M$ . В итоге:

$$\begin{aligned} f(\bar{x}) - f^* &= f\left(\frac{1}{T} \sum_{k=0}^{T-1} x_k\right) - f^* \leq \frac{1}{T} \left( \sum_{k=0}^{T-1} f(x_k) - f^* \right) \\ &\leq \frac{1}{T} \left( \sum_{k=0}^{T-1} \langle g_k, x_k - x^* \rangle \right) \\ &\leq \frac{M}{\alpha T} + \frac{\alpha G^2}{2} \leq \sqrt{\frac{2MG^2}{T}} \end{aligned}$$

Выбирая шаг  $\alpha_k = \alpha = \sqrt{\frac{2M}{G^2 T}}$

## 2.4 Алгоритм зеркального спуска (mirror descent):

$$x_{k+1} = \arg \min_{x \in S} (\langle \alpha_k g_k, x \rangle + V_{x_k}(x))$$

Интересные фишки:

- Такая же скорость сходимости, как и для метода проекции субградиента.
- Работает в существенно более широком классе практических задач.

## 2.5 Ценность

В случае, если мы выбрали  $\|\cdot\| = \|\cdot\|_2$  Евклидову норму и Евклидово расстояние, то этот метод в точности совпадает с тем, что мы уже называем методом проекции субградиента.

Значит, надо предоставить сценарий, когда МЗС работает лучше, давайте рассмотрим  $S = \Delta_n$  - вероятностный симплекс, а так же следующее расстояние Брэгмана  $V_x(y) = \sum_{i \in [n]} y_i \log \frac{y_i}{x_i} = D(y||x)$ . Норма в прямом пространстве при этом  $\|\cdot\|_1$ , а в сопряженном -  $\|\cdot\|_\infty$ . Кроме того, для заданной дивергенции Брэгмана справедливо:

$$x_0 = (1/n, \dots, 1/n) \rightarrow V_{x_0}(x) \leq \log n \quad \forall x \in \Delta_n$$

Тогда алгоритм зеркального спуска запишется в виде:

$$\begin{aligned} x_{k+1} &= \arg \min_{x \in S} (\langle \alpha_k g_k, x \rangle + V_{x_k}(x)) \\ &= \arg \min_{x \in S} \left( \langle \alpha_k g_k, x \rangle + \sum_{i \in [n]} x_i \log \frac{x_i}{x_{k_i}} \right) \\ &= x_k \cdot \frac{e^{-\alpha_k g_k}}{\|x_k \cdot e^{-\alpha_k g_k}\|_1} \end{aligned}$$

А оценки с учетом того, что  $M = \log n, \|g_k\|_\infty \leq G$  запишутся, как:

$$f(\bar{x}) - f^* \leq \sqrt{\frac{2 \log(n) G^2}{T}}$$

Таким образом, получаем алгоритм зеркального спуска:

---

**Algorithm 1** Mirror Descent

---

**Input:**  $x_0, f(x), \nabla f(x), \alpha$

- 1: **for**  $k = 0, 1, \dots, K$  **do**
- 2:    $x_{k+1} = \arg \min_{x \in S} (\langle \alpha_k g_k, x \rangle + V_{x_k}(x))$
- 3: **end for**

**Output:**  $x_{K+1}$

---

## 3 Описание методов

### 3.1 Двойственные усреднения

Предлагается исследовать также метод двойственных усреднений. В общем виде:

---

**Algorithm 2** Dual Averaging

---

**Input:** Set  $s_0 = 0$ , Choose  $\beta_0 > 0$ .

- 1: **for**  $k = 0, 1, \dots, K$  **do**
  - 2:   Compute  $g_k = \nabla f(x_k)$
  - 3:   Choose  $\lambda_k > 0$ . Set  $s_{k+1} = s_k + \lambda_k g_k$
  - 4:   Choose  $\beta_{k+1} \geq \beta_k$ . Set  $x_{k+1} = \pi_{\beta_{k+1}}(-s_{k+1})$ .
  - 5: **end for**
- 

Где  $\pi_\beta(s) = \arg \min_{x \in Q} (-\langle s, x \rangle + \beta d(x))$ , причем  $d(x) = \sum_i x_i \log x_i$ .

Тогда, получаем:

$$\begin{aligned} & \arg \min_{x \in Q} (-\langle s, x \rangle + \beta \sum_i x_i \log x_i) \\ &= \arg \min (\langle \frac{-s}{\beta}, x \rangle + \sum_i x_i \log \frac{x_i}{x_0} + \sum_i x_i \log x_0) \\ &= \arg \min (\langle \frac{-s}{\beta}, x \rangle + \sum_i x_i \log \frac{x_i}{x_0} - \sum_i x_i \log n) \\ &= \arg \min (\langle \frac{-s}{\beta}, x \rangle + \sum_i x_i \log \frac{x_i}{x_0} - \log n) \\ &= \arg \min (\langle \frac{-s}{\beta}, x \rangle + \sum_i x_i \log \frac{x_i}{x_0}) \\ &= x_0 \cdot \frac{e^{\frac{s}{\beta}}}{\|x_0 \cdot e^{\frac{s}{\beta}}\|} \\ &= \frac{e^{\frac{s}{\beta}}}{\|e^{\frac{s}{\beta}}\|} \end{aligned}$$

А значит, можно выразить  $x_{k+1} = x_k \cdot \frac{e^{-g_k \alpha}}{\|x_k e^{-g_k \alpha}\|}$ .

### 3.2 Метод подобных треугольников

Заметим, что оба, описанных выше метода могут быть ускорены с помощью метода подобных треугольников.

---

#### Algorithm 3 Similar Triangles

---

$$\begin{aligned} y_{k+1} &= \frac{\alpha_{k+1} u_k + A_k x_k}{A_{k+1}} \\ u_{k+1} &= \arg \min_{x \in Q} \varphi_{k+1}(x) \\ x_{k+1} &= \frac{\alpha_{k+1} u_{k+1} + A_k x_k}{A_{k+1}} \\ A_k &= \sum_{i=0}^k \alpha_i, \alpha_0 = L^{-1}, x_0 = u_0 = \arg \min_{x \in Q} \varphi_0(x) \end{aligned}$$


---

Где  $\alpha_{k+1}$  можно задавать рекуррентно:

$$\alpha_{k+1} = \frac{1}{2L} + \sqrt{\frac{1}{4L^2} + \alpha_k^2},$$

и тогда мы получим еще 2 метода TR-MD и TR-DA.

Но можно подойти к выбору  $\alpha_k$  чуть более нестандартно.

Возьмем:

$$\alpha_k = \arg \min_{\alpha_k \in M} (f(y_k)) = \arg \min_{\alpha_k \in M} f(\alpha_{k+1} u_k + (1 - \alpha_{k+1}) x_k)$$

Таким образом вывели еще два оптимизированных методом подобных треугольников, но для других альфа алгоритма TR-MD2 и TR-DA2.

## 4 Эксперименты

В ходе экспериментов мы тестируем работу полученных выше алгоритмов и сравниваем скорость их сходимости к точному решению. Для тестирования взяли функцию:

$$f(x) = \|Ax - b\|_2^2$$

$$\nabla f(x) = 2A^T(Ax - b)$$

И будем искать ее минимум на выпуклом множестве  $S : \left\{ x \in S : x \geq 0, \sum_{i \in [n]} x_i = 1 \right\}$  (вероятностном симплексе).

Но для последних 2-х методов знания значений градиента оказывается недостаточно. Необходимо в явном виде выразить  $\alpha$ .

$$\alpha = \arg \min_{\alpha} f(\alpha x^n + (1 - \alpha)y^n)$$

$$\sum_{k=1}^n (x_k^n - y_k^n) \frac{\partial f(\alpha x^n + (1 - \alpha)y^n)}{\partial x_k}$$

$$(x^n - y^n)^T \nabla f(\alpha x^n + (1 - \alpha)y^n) = 0$$

$$(x^n - y^n)^T 2A^T (A(\alpha x^n + (1 - \alpha)y^n) - b) = 0$$

$$2(x^n - y^n)^T (\alpha (A^T (Ax^n - b)) + (1 - \alpha) (A^T (Ay^n - b))) = 0$$

$$(x^n - y^n)^T (\alpha \nabla f(x^n) + (1 - \alpha) \nabla f(y^n)) = 0$$

$$\alpha = \begin{cases} const = 0 & (x^n - y^n)^T (\nabla f(x^n) - \nabla f(y^n)) = 0 \\ -\frac{(x^n - y^n)^T (\nabla f(y^n))}{(x^n - y^n)^T (\nabla f(x^n) - \nabla f(y^n))} & else \end{cases}$$

Полученные результаты представлены на графиках.




Рис. 1: На левом графике результаты работы для метода зеркального спуска и его ускорений, на правом аналогично для метода двойственных усреднений.



## 5 Заключение

В данной работе был реализован метод зеркального спуска и рассмотрены различные его вариации. Нетрудно заметить из графиков, что ускорение получается более чем существенное и ускоренные методы сходятся значительно быстрее. Наиболее быстрым оказывается метод двойственных с взвешенными  $\lambda$  оптимизированный методом подобных треугольников с особым выбором коэффициента  $\alpha$ .

### Responsibilities:

- Code director - Якушев А.Ю.
- Text director - Ефремов С.В.

## Список литературы

- [1] *Гасников А.В.* Современные численные методы оптимизации. Метод универсального градиентного спуска
- [2] *Камзолов Д.И.* Семинары 674 группы
- [3] *Камзолов Д.И.* Презентации 674 группы
- [4] *Нестеров Ю.* Primal-dual subgradient methods for convex problems
- [5] *Гасников А.В., Нестеров Ю.Е.* Универсальный метод для задач стохастической композитной оптимизации
- [6] *Меркулов Д.* Презентации